



TRABALHO INTERDISCIPLINAR V • PUC MINAS

# Load Balancer para Modelos de IA

*Roteamento de requisições por complexidade entre modelos de IA de diferentes portes*

---

Artur Fernandes Braga de Menezes • Artur Rizzi Martinho • Felipe Lacerda Tertuliano • Gabriel Alves da Silva Diógenes • Rafael Mortimer Colares

## CONTEXTO

# Um modelo só para tudo

Sistemas de IA em produção enviam toda requisição — simples ou complexa — para o mesmo modelo de grande porte.



Uso ineficiente de GPU/CPU em tarefas simples



Maior latência e custo de inferência




Demanda heterogênea, capacidade subutilizada



## HIPÓTESE

# Rotear pela complexidade do pedido

Um load balancer que classifica cada prompt e o direciona ao modelo mais adequado — evitando usar um modelo grande quando um modelo leve resolve.



Serviço via Ollama · orquestração em Python (FastAPI + httpx)

## OBJETIVOS

# O que o trabalho pretende mostrar



### Objetivo geral

Desenvolver um load balancer que direcione requisições entre modelos de IA de portes distintos, conforme sua complexidade.



Implementar um classificador de prompts



Reduzir latência média e custo de inferência



Comparar baseline (um único modelo) x proposta



Medir uso de RAM e GPU por instância

# O que já existe — e o que falta



**Kossmann et al. (2024)**

SAL — balanceia pela carga de fila e memória do servidor



**Jain et al. (2025)**

Prevê tamanho da resposta entre réplicas do mesmo modelo



**Sun et al. (2024) — Llumnix**

Reagenda requisições em execução entre instâncias



**Xia et al. (2025) — SkyWalker**

Balanceamento entre regiões geográficas



**Yuan et al. (2026) — DualMap**

Concilia afinidade de cache com balanceamento de carga

*Lacuna: nenhum classifica a complexidade do prompt para escolher entre modelos de portes diferentes.*

## Baseline x proposta, em medição



### Baseline

Todas as requisições vão para o modelo de maior porte.




### Proposta

O LoadBalancer classifica o prompt e encaminha ao modelo mais adequado.

- Latência média, P95 e P99
- Uso de RAM e GPU por máquina
- Identificação de outliers

## METODOLOGIA

# Cronograma do semestre





# Obrigado

*Perguntas e discussão*

---

Artur Fernandes Braga de Menezes · Artur Rizzi Martinho · Felipe Lacerda Tertuliano · Gabriel Alves da Silva Diógenes · Rafael Mortimer Colares

PUC Minas · Trabalho Interdisciplinar V